New Horizons®
Centro de Capacitación

# Curso

## Taller de IA con .NET

Docente: Ing. Edwin Fidel Barrientos Retuerto

New Horizons®
Centro de Capacitación

# Módulo 6:

## Agentes con Contexto y Memoria

**Objetivo del módulo:** Integrar contexto y memoria persistente en agentes inteligentes

New Horizons®
Centro de Capacitación

# Sesión 6:

# Agentes con Contexto y Memoria

New Horizons®
Centro de Capacitación

# Agenda

- Memoria de Corto y Largo Plazo
- Integración MCP + Agentes
- Persistencia de estado
- Mejora de respuesta

# Introducción al Ecosistema Foundry

Microsoft Foundry es una plataforma integral diseñada para la **creación, despliegue y gestión** de aplicaciones y agentes de IA a escala empresarial, ofreciendo un entorno unificado y robusto.

### Enfoque Modular

Arquitectura basada en componentes intercambiables que permiten adaptar la solución a necesidades específicas de negocio.

### Interoperable

Capacidad nativa para conectar modelos de lenguaje (LLMs), herramientas externas y diversas fuentes de datos empresariales.

### Seguro y Confiable

Garantiza la gobernanza de datos y el cumplimiento de estándares empresariales en todo el ciclo de vida del agente.

### Escala Empresarial

Optimizado para manejar cargas de trabajo críticas, desde la orquestación simple hasta flujos de trabajo multi-agente complejos.

# Arquitectura General de una Aplicación

Estructura modular y flujo de orquestación en Microsoft Foundry

New Horizons
Centro de Capacitación

## Interfaz de Usuario

Punto de interacción

## Foundry Agent Service

Orquestador Central: Cerebro y Coordinador

## Modelos (LLMs)

Comprensión de lenguaje natural y razonamiento (GPT, Claude).

## Foundry IQ

Almacén de conocimiento empresarial con Azure AI Search.

## Herramientas (Tools)

Integración con APIs externas y sistemas mediante MCP.

- El **Foundry Agent Service** gestiona el estado, las sesiones y la invocación de herramientas de forma transparente para el desarrollador .NET.
- La integración con **Foundry IQ** permite que el agente fundamente sus respuestas en datos reales de la organización (RAG).

# El Rol Central del Foundry Agent Service

El cerebro orquestador de la arquitectura de agentes

New Horizons®
Centro de Capacitación

## Gestión del Flujo

Dirige la secuencia lógica de la conversación, asegurando que el agente responda de manera coherente a través de múltiples turnos.

## Control de Estado

Mantiene el contexto de la sesión de forma transparente, incluyendo el historial de chat, metadatos y variables del agente.

## Invocación de Herramientas

Decide cuándo y qué herramientas externas o APIs llamar para realizar acciones específicas o recuperar datos externos.

## Interacción con LLMs

Actúa como puente entre la lógica del agente y los modelos de lenguaje, enviando prompts y procesando las respuestas generadas.

**Abstrae la complejidad de la infraestructura, permitiendo al desarrollador .NET centrarse en la lógica del negocio.**

# Integración de Modelos de Lenguaje LLM

El motor de inteligencia detrás de cada interacción en Foundry.

New Horizons®
Centro de Capacitación

### Comprensión

Interpretación profunda del lenguaje natural para captar la intención y el sentimiento del usuario con precisión.

### Razonamiento

Capacidad de lógica avanzada para descomponer tareas complejas, evaluar opciones y planificar acciones.

### Generación

Creación de respuestas fluidas, coherentes y fundamentadas en el contexto empresarial específico.

## Ecosistema Abierto y Flexible

Foundry permite la integración de una amplia variedad de modelos de vanguardia como **GPT-4**, **Claude** y otros modelos especializados, permitiendo elegir el mejor recurso para cada tarea.

MULTI-MODEL

AGNÓSTICO

# Fundamentos de la Gestión de Memoria

New Horizons
Centro de Capacitación

La capacidad de **recordar** es el pilar que permite pasar de simples respuestas reactivas a **interacciones inteligentes y personalizadas**.

## ¿Por qué es crucial?

### Personalización
Adapta el comportamiento según las preferencias y el historial del usuario.

### Continuidad
Mantiene el hilo conductor a través de múltiples sesiones y dispositivos.

### Contextualización
Provee al LLM de la información necesaria para fundamentar sus respuestas.

## Taxonomía de la Memoria

### Memoria a Corto Plazo
Contexto inmediato de la conversación actual.

### Memoria a Largo Plazo
Conocimiento persistente entre sesiones y flujos.

EXTRACCIÓN CONSOLIDACIÓN RECUPERACIÓN

# Memoria a Corto Plazo: El contexto del trabajo

Conocida como **contexto de trabajo**, rastrea la conversación actual y mantiene el contexto inmediato necesario para las interacciones en curso.

## Gestión Automática

El **Foundry Agent Service** gestiona esta memoria de forma transparente como parte del contexto de la sesión.

## Interacciones Multi-Turno

Asegura la coherencia al recordar los mensajes previos dentro del flujo activo, permitiendo respuestas contextualizadas.

# Memoria a Largo Plazo: Persistencia del Conocimiento

Es el **conocimiento persistente** que un agente retiene a través de múltiples sesiones, dispositivos y flujos de trabajo.

### Continuidad Histórica

Retención del historial de conversaciones previas para evitar redundancias y mantener el hilo conductor.

### Personalización Real

Recordatorio de preferencias específicas del usuario, como restricciones dietéticas o estilos de trabajo.

### Omnicanalidad

Acceso a la misma base de conocimientos sin importar el dispositivo o el punto de acceso del usuario.

### Solución Gestionada en Foundry Agent Service

Abstrae la complejidad técnica de extraer, consolidar y gestionar el almacén de memoria persistente.

# Fases de la Memoria: Extracción

La extracción es la fase inicial donde el sistema **identifica y captura** información vital del flujo de conversación para su almacenamiento persistente.

### Entrada

Conversación activa y contexto del usuario

### Inteligencia

Detección de entidades, hechos y sentimientos

### Memoria

Datos estructurados listos para consolidar

### ¿Qué se extrae?

- ✓ Preferencias explícitas del usuario.
- ✓ Hechos concretos y datos técnicos.
- ✓ Contexto relevante de la sesión.

### Ejemplos Prácticos

*"Soy alérgico a los lácteos"*

*"Prefiero reportes en formato JSON"*

*"Resumen de la última reunión de ventas"*

# Fases de la Memoria: Consolidación de Datos

New Horizons®
Centro de Capacitación

### Fusión de Temas

Los **LLMs** identifican y fusionan automáticamente temas similares o duplicados detectados durante la extracción.

### Resolución de Conflictos

Se analizan hechos contradictorios (ej. cambio en preferencias del usuario) para mantener la **precisión** de la memoria.

### Optimización de Almacén

Elimina la redundancia para que el sistema de recuperación sea más **rápido y eficiente** en futuras consultas.

**El proceso de consolidación garantiza que el agente aprenda y evolucione sin acumular ruido informativo.**

# Fases de la Memoria: Recuperación Inteligente

La fase de **Recuperación** es el momento en que el agente accede al conocimiento almacenado para fundamentar su respuesta actual, asegurando continuidad y relevancia.

### Búsqueda de Relevancia

El sistema identifica y extrae las memorias más pertinentes del almacén persistente basándose en el prompt actual.

### Acceso al Contexto

Permite al agente recuperar rápidamente el contexto adecuado sin necesidad de re-procesar todo el historial.

### Interacción Natural

Al "recordar" detalles previos, las conversaciones se sienten fluidas, informadas y personalizadas para el usuario.

**Resultado:** Elimina la necesidad de que el usuario repita información previamente compartida.

**Foundry Agent Service**

# El cerebro del Agente

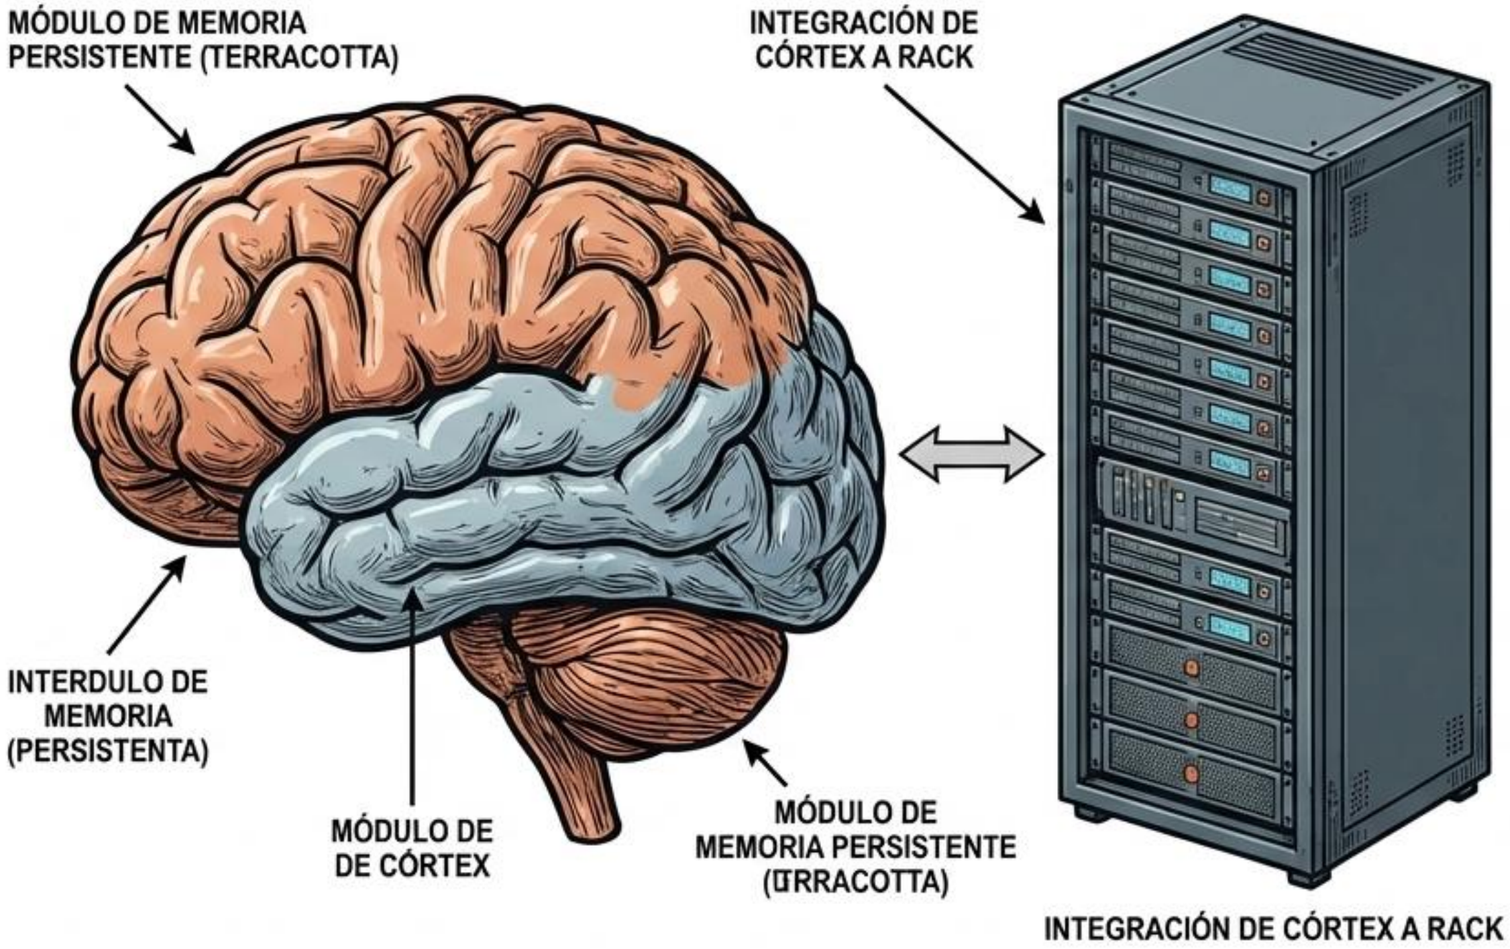


## FLUJO DE DATOS DE AGENTE

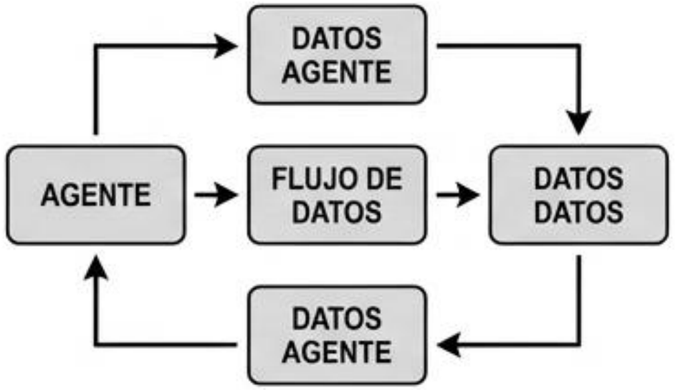


## DIAGNÓSTICO DE SISTEMA PRINCIPAL

| SISTEMA ID | DESCRIPCION |
|---|---|
| 0N-T1 | Contnuto de memoria persistente |
| 0H-T2 | Preclocato de sistema |
| 0N-T3 | Caracteristiiros de agente |
| 0N-T4 | Integración de sistema principal |
| 0N-T5 | Diagnóstico de sistema principal |

# Chatbots vs Agentes

## Modelos Base (Stateless)

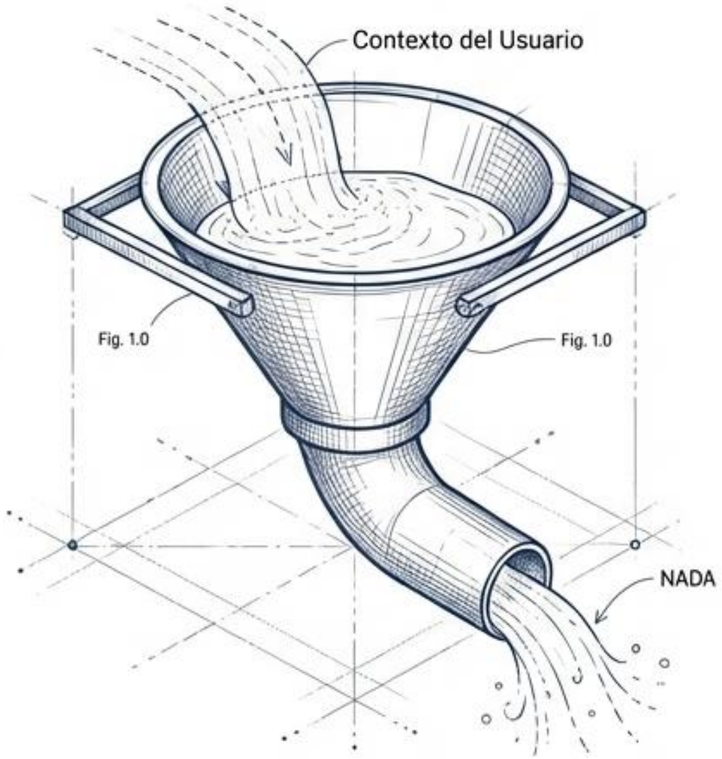


Excelentes para razonamiento aislado, pero sufren de amnesia total. Al cerrar la sesión, el contexto desaparece. Limitados a ser chatbots reactivos.

## Cognición Persistente (Stateful)

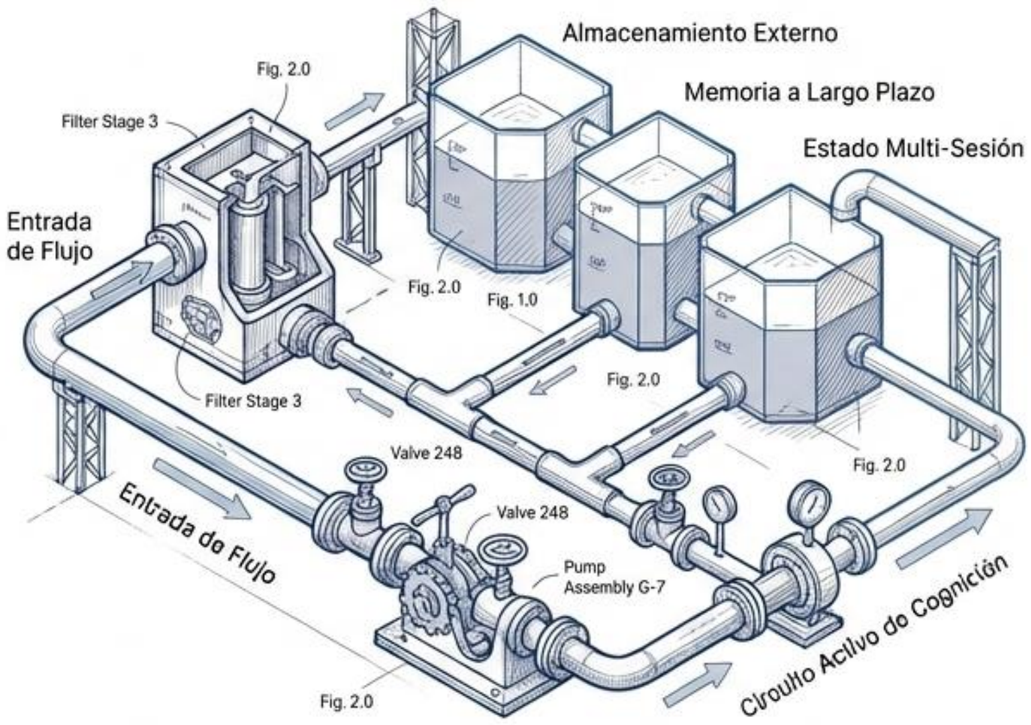


Requieren operar a lo largo de semanas o meses. Adaptan su comportamiento, manejan flujos de trabajo multi-sesión y acumulan contexto mediante almacenamiento externo.

# Arquitectura de la Memoria IA

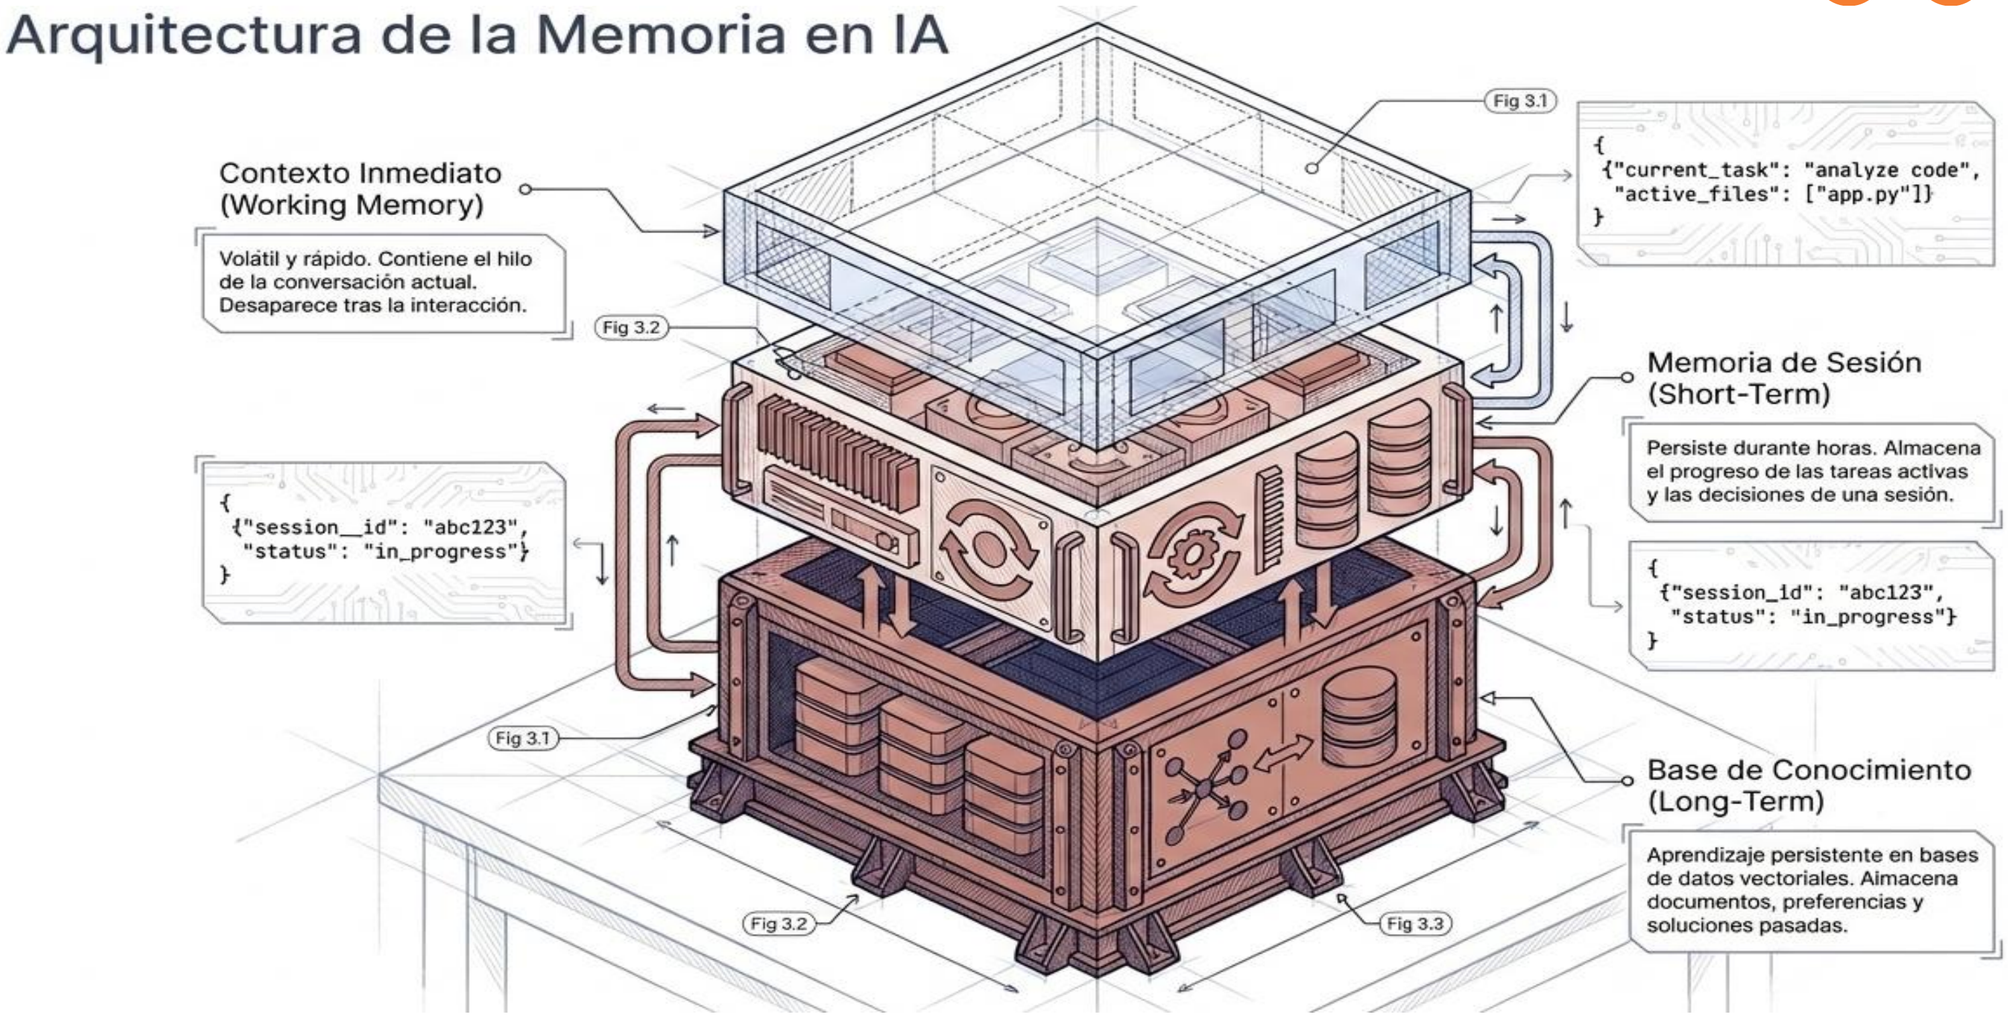

# Tipos de Memoria: Hechos y Preferencias

Clasificación de la información persistente en Foundry Agent Service.

## Hechos (Facts)

*"Información objetiva y verificable sobre el usuario o el entorno."*

- **Datos Biográficos:** Nombres, roles y relaciones clave.
- **Contexto Crítico:** Alergias, restricciones legales o requisitos técnicos.
- **Historial de Eventos:** Resúmenes de actividades o decisiones pasadas.

## Preferencias

*"Datos subjetivos que personalizan la experiencia y el tono del agente."*

- **Estilo de Comunicación:** Tono formal/informal, nivel de detalle.
- **Formatos Favoritos:** Tablas, listas, código o lenguaje natural.
- **Prioridades:** Temas de interés recurrente o canales de entrega.

Ambos tipos de memoria se **consolidan** automáticamente para evitar redundancias y resolver conflictos.

# Persistencia de Estado en Flujo de IA

New Horizons
Centro de Capacitación

La persistencia del estado es un pilar fundamental para construir flujos de trabajo de IA **robustos y de larga duración**. Microsoft Foundry abstrae esta complejidad, permitiendo que el desarrollador se centre en la lógica del negocio.

### Abstracción de Complejidad

Elimina la necesidad de gestionar manualmente la infraestructura de almacenamiento y el historial de mensajes.

### Continuidad Fluida

Asegura interacciones naturales en múltiples turnos, manteniendo el contexto operativo sin interrupciones.

### Integridad de Datos

Persiste llamadas a herramientas, instrucciones del agente y metadatos críticos de forma segura y auditada.

**APIS TRADICIONALES**

Historial Manual

**MICROSOFT FOUNDRY**

**Estado Gestionado Automáticamente**

# Gestión Automática en Hosted Agents

Abstracción de la complejidad para desarrolladores .NET

New Horizons
Centro de Capacitación

## Elementos Gestionados por el Runtime

### Historial de Conversación

Continuidad fluida en interacciones de múltiples turnos.

### Llamadas y Salidas de Herramientas

Gestión transparente de la ejecución de funciones externas.

### Instrucciones y Metadatos

Persistencia de la configuración y contexto operativo.

## Experiencia de Desarrollo (.NET)

- **Simplificación Radical:** No es necesario pasar manualmente el historial en cada solicitud API.
- **Enfoque en Lógica:** Los desarrolladores se centran en la lógica del negocio, no en la infraestructura de estado.
- **Robustez Nativa:** El runtime de Foundry maneja reintentos y consistencia de datos automáticamente.

> *"El runtime gestiona de forma transparente el estado, reduciendo significativamente la carga de desarrollo."*

# Infraestructura de Persistencia: Azure Cosmos DB

New Horizons
Centro de Capacitación

## Estado Operativo del Agente

- **Conversaciones de Chat:** Historial completo de interacciones para continuidad.
- **Definiciones del Agente:** Configuraciones, instrucciones y metadatos.
- **Persistencia NoSQL:** Escalabilidad y rendimiento para flujos de IA.

## Gobernanza y Aislamiento

- **Suscripción del Cliente:** Los recursos se aprovisionan en el entorno del cliente.
- **Aislamiento Robusto:** Control total sobre la residencia y retención de datos.
- **Auditabilidad:** Cumplimiento de normativas empresariales de seguridad.

**Importante:** Para evitar inconsistencias, otras aplicaciones no deben interactuar directamente con las colecciones gestionadas por el servicio.

# Almacenamiento Dedicado con Azure Storage

New Horizons®
Centro de Capacitación

El runtime de **Foundry Agent Service** utiliza cuentas de almacenamiento dedicadas en la **suscripción del cliente** para gestionar de forma segura los archivos de las sesiones de chat.

### Control de Acceso Granular

Gestión precisa de quién puede leer o escribir archivos utilizando políticas de identidad nativas de Azure.

### Capacidades de Auditoría

Registro completo de accesos y modificaciones para cumplir con los requisitos de seguridad corporativa.

### Residencia de Datos

Asegura que los documentos y archivos permanezcan dentro de las fronteras geográficas definidas por la organización.

### Gobernanza y Retención

Aplicación de políticas de ciclo de vida de datos y retención legal directamente sobre el almacenamiento dedicado.

** Nota: El servicio gestiona los datos, pero la propiedad y el control de la infraestructura pertenecen íntegramente al cliente.*

# Patrón Asíncrono de Larga Duración

New Horizons®
Centro de Capacitación

Optimización de flujos que exceden los tiempos de espera HTTP estándar (30s a varios minutos), garantizando resiliencia y continuidad.

## PASO 1

**Solicitud Inicial**

La API devuelve inmediatamente un estado **202 Accepted** junto con un ID de tarea único.

## PASO 2

**Procesamiento en Background**

Un trabajador en segundo plano ejecuta el flujo de trabajo complejo del agente sin bloquear al cliente.

## PASO 3

**Persistencia de Estado**

El progreso y los resultados se guardan de forma duradera en **Azure Cosmos DB**.

## PASO 4

**Monitoreo y Resultado**

El cliente consulta periódicamente el estado mediante el ID de tarea para obtener el resultado final.

# Optimización de Respuestas: Groundry con Foundry IQ

Conectando Agentes al Conocimiento Empresarial mediante Azure AI Search

New Horizons®
Centro de Capacitación

## Sistema de Conocimiento Centralizado

Foundry IQ actúa como el núcleo de información, eliminando la necesidad de gestionar múltiples fuentes de datos de forma individual. Permite una conexión unificada a toda la base de conocimiento corporativa.

### Recuperación Agéntica

Búsqueda inteligente que entiende el contexto del agente para extraer solo la información más relevante.

### Fuentes Conectadas

- ✓ SharePoint
- ✓ Fabric OneLake
- ✓ Web Corporativa

### Impacto en Calidad

Respuestas fundamentadas (grounded) con contexto profundo, reduciendo alucinaciones y aumentando la precisión.

# Orquestación MultiAgente

Sustitución de sistemas monolíticos por ecosistemas de agentes especializados.

New Horizons®
Centro de Capacitación

### Análisis de Datos

Procesamiento profundo y extracción de insights técnicos.

### Redacción

Generación de informes y documentación estructurada.

### Interacción

Gestión de la comunicación directa con el usuario final.

**Mayor Calidad** | **Alta Precisión** | **Eficiencia Operativa**

# GRACIAS