New Horizons®
Centro de Capacitación

Curso

Taller de IA con .NET

Docente: Ing. Edwin Fidel Barrientos Retuerto

New Horizons®
Centro de Capacitación

Introducción a IA Generativa y Consumo de IA .NET

Objetivo del módulo: Integrar agentes de IA dentro de aplicaciones .NET reales

New Horizons®
Centro de Capacitación

Sesión 7:

Integración de Agentes en aplicaciones .NET

New Horizons®
Centro de Capacitación

Agenda

- Integración con APIs y servicios existentes.
- Uso básico de base de datos.
- Flujo de IA dentro de una aplicación.
- Caso práctico empresarial.

Introducción al Ecosistema Microsoft Foundry

New Horizons®
Centro de Capacitación

Microsoft Foundry es una plataforma integral diseñada para la **creación, despliegue y gestión** de aplicaciones y agentes de IA a escala empresarial, ofreciendo un entorno unificado y robusto.

Enfoque Modular

Arquitectura basada en componentes intercambiables que permiten adaptar la solución a necesidades específicas de negocio.

Interoperable

Capacidad nativa para conectar modelos de lenguaje (LLMs), herramientas externas y diversas fuentes de datos empresariales.

Seguro y Confiable

Garantiza la gobernanza de datos y el cumplimiento de estándares empresariales en todo el ciclo de vida del agente.

Escala Empresarial

Optimizado para manejar cargas de trabajo críticas, desde la orquestación simple hasta flujos de trabajo multi-agente complejos.

Arquitectura General de una aplicación

Estructura modular y flujo de orquestación en Microsoft Foundry

New Horizons
Centro de Capacitación

Interfaz de Usuario

Punto de interacción

Foundry Agent Service

Orquestador Central:
Cerebro y Coordinador

Modelos (LLMs)

Comprensión de lenguaje natural y razonamiento (GPT, Claude).

Foundry IQ

Almacén de conocimiento empresarial con Azure AI Search.

Herramientas (Tools)

Integración con APIs externas y sistemas mediante MCP.

- El **Foundry Agent Service** gestiona el estado, las sesiones y la invocación de herramientas de forma transparente para el desarrollador .NET.
- La integración con **Foundry IQ** permite que el agente fundamente sus respuestas en datos reales de la organización (RAG).

El Rol Central de Foundry Agent Service

El cerebro orquestador de la arquitectura de agentes

New Horizons®
Centro de Capacitación

Gestión del Flujo

Dirige la secuencia lógica de la conversación, asegurando que el agente responda de manera coherente a través de múltiples turnos.

Control de Estado

Mantiene el contexto de la sesión de forma transparente, incluyendo el historial de chat, metadatos y variables del agente.

Invocación de Herramientas

Decide cuándo y qué herramientas externas o APIs llamar para realizar acciones específicas o recuperar datos externos.

Interacción con LLMs

Actúa como puente entre la lógica del agente y los modelos de lenguaje, enviando prompts y procesando las respuestas generadas.

Abstrae la complejidad de la infraestructura, permitiendo al desarrollador .NET centrarse en la lógica del negocio.

Integración de los Modelos de Lenguaje (LLM)

El motor de inteligencia detrás de cada interacción en Foundry.

New Horizons®
Centro de Capacitación

Comprensión

Interpretación profunda del lenguaje natural para captar la intención y el sentimiento del usuario con precisión.

Razonamiento

Capacidad de lógica avanzada para descomponer tareas complejas, evaluar opciones y planificar acciones.

Generación

Creación de respuestas fluidas, coherentes y fundamentadas en el contexto empresarial específico.

Ecosistema Abierto y Flexible

Foundry permite la integración de una amplia variedad de modelos de vanguardia como **GPT-4**, **Claude** y otros modelos especializados, permitiendo elegir el mejor recurso para cada tarea.

MULTI-MODEL

AGNÓSTICO

** Los LLMs actúan como el componente de inteligencia procesado por el Foundry Agent Service.*

Fundamentos de la Gestión de Memoria

La capacidad de **recordar** es el pilar que permite pasar de simples respuestas reactivas a **interacciones inteligentes y personalizadas**.

¿Por qué es crucial?

Personalización

Adapta el comportamiento según las preferencias y el historial del usuario.

Continuidad

Mantiene el hilo conductor a través de múltiples sesiones y dispositivos.

Contextualización

Provee al LLM de la información necesaria para fundamentar sus respuestas.

Taxonomía de la Memoria

Memoria a Corto Plazo

Contexto inmediato de la conversación actual.

Memoria a Largo Plazo

Conocimiento persistente entre sesiones y flujos.

Memoria a Corto Plazo: El Contexto de Trabajo

New Horizons
Centro de Capacitación

Conocida como **contexto de trabajo**, rastrea la conversación actual y mantiene el contexto inmediato necesario para las interacciones en curso.

Gestión Automática

El **Foundry Agent Service** gestiona esta memoria de forma transparente como parte del contexto de la sesión.

Interacciones Multi-Turno

Asegura la coherencia al recordar los mensajes previos dentro del flujo activo, permitiendo respuestas contextualizadas.

Memoria a Largo Plazo: Persistencia del Conocimiento

Es el **conocimiento persistente** que un agente retiene a través de múltiples sesiones, dispositivos y flujos de trabajo.

Continuidad Histórica

Retención del historial de conversaciones previas para evitar redundancias y mantener el hilo conductor.

Personalización Real

Recordatorio de preferencias específicas del usuario, como restricciones dietéticas o estilos de trabajo.

Omnicanalidad

Acceso a la misma base de conocimientos sin importar el dispositivo o el punto de acceso del usuario.

Solución Gestionada en Foundry Agent Service

Abstrae la complejidad técnica de extraer, consolidar y gestionar el almacén de memoria persistente.

Fases de la Memoria: Extracción

La extracción es la fase inicial donde el sistema **identifica y captura** información vital del flujo de conversación para su almacenamiento persistente.

Entrada

Conversación activa y contexto del usuario

Inteligencia

Detección de entidades, hechos y sentimientos

Memoria

Datos estructurados listos para consolidar

¿Qué se extrae?

- ✓ Preferencias explícitas del usuario.
- ✓ Hechos concretos y datos técnicos.
- ✓ Contexto relevante de la sesión.

Ejemplos Prácticos

"Soy alérgico a los lácteos"

"Prefiero reportes en formato JSON"

"Resumen de la última reunión de ventas"

Fases de la Memoria: Consolidación de Datos

New Horizons
Centro de Capacitación

Fusión de Temas

Los **LLMs** identifican y fusionan automáticamente temas similares o duplicados detectados durante la extracción.

Resolución de Conflictos

Se analizan hechos contradictorios (ej. cambio en preferencias del usuario) para mantener la **precisión** de la memoria.

Optimización de Almacén

Elimina la redundancia para que el sistema de recuperación sea más **rápido y eficiente** en futuras consultas.

El proceso de consolidación garantiza que el agente aprenda y evolucione sin acumular ruido informativo.

Fases de la Memoria: Recuperación Inteligente

New Horizons®
Centro de Capacitación

La fase de **Recuperación** es el momento en que el agente accede al conocimiento almacenado para fundamentar su respuesta actual, asegurando continuidad y relevancia.

Búsqueda de Relevancia

El sistema identifica y extrae las memorias más pertinentes del almacén persistente basándose en el prompt actual.

Acceso al Contexto

Permite al agente recuperar rápidamente el contexto adecuado sin necesidad de re-procesar todo el historial.

Interacción Natural

Al "recordar" detalles previos, las conversaciones se sienten fluidas, informadas y personalizadas para el usuario.

Resultado: Elimina la necesidad de que el usuario repita información previamente compartida.

Foundry Agent Service

Tipos de Memoria: Hechos y Preferencias

New Horizons
Centro de Capacitación

Clasificación de la información persistente en Foundry Agent Service.

Hechos (Facts)

"Información objetiva y verificable sobre el usuario o el entorno."

- **Datos Biográficos:** Nombres, roles y relaciones clave.
- **Contexto Crítico:** Alergias, restricciones legales o requisitos técnicos.
- **Historial de Eventos:** Resúmenes de actividades o decisiones pasadas.

Preferencias

"Datos subjetivos que personalizan la experiencia y el tono del agente."

- **Estilo de Comunicación:** Tono formal/informal, nivel de detalle.
- **Formatos Favoritos:** Tablas, listas, código o lenguaje natural.
- **Prioridades:** Temas de interés recurrente o canales de entrega.

Ambos tipos de memoria se **consolidan** automáticamente para evitar redundancias y resolver conflictos.

Persistencia de Estado en Flujos de IA

New Horizons
Centro de Capacitación

La persistencia del estado es un pilar fundamental para construir flujos de trabajo de IA **robustos y de larga duración**. Microsoft Foundry abstrae esta complejidad, permitiendo que el desarrollador se centre en la lógica del negocio.

Abstracción de Complejidad

Elimina la necesidad de gestionar manualmente la infraestructura de almacenamiento y el historial de mensajes.

Continuidad Fluida

Asegura interacciones naturales en múltiples turnos, manteniendo el contexto operativo sin interrupciones.

Integridad de Datos

Persiste llamadas a herramientas, instrucciones del agente y metadatos críticos de forma segura y auditada.

APIS TRADICIONALES

Historial Manual

MICROSOFT FOUNDRY

Estado Gestionado Automáticamente

Gestión Automática en Hosted Agents

Abstracción de la complejidad para desarrolladores .NET

New Horizons
Centro de Capacitación

Elementos Gestionados por el Runtime

Historial de Conversación

Continuidad fluida en interacciones de múltiples turnos.

Llamadas y Salidas de Herramientas

Gestión transparente de la ejecución de funciones externas.

Instrucciones y Metadatos

Persistencia de la configuración y contexto operativo.

Experiencia de Desarrollo (.NET)

- **Simplificación Radical:** No es necesario pasar manualmente el historial en cada solicitud API.
- **Enfoque en Lógica:** Los desarrolladores se centran en la lógica del negocio, no en la infraestructura de estado.
- **Robustez Nativa:** El runtime de Foundry maneja reintentos y consistencia de datos automáticamente.

> *"El runtime gestiona de forma transparente el estado, reduciendo significativamente la carga de desarrollo."*

Infraestructura de Persistencia: Azure Cosmos DB

New Horizons
Centro de Capacitación

Estado Operativo del Agente

- **Conversaciones de Chat:** Historial completo de interacciones para continuidad.
- **Definiciones del Agente:** Configuraciones, instrucciones y metadatos.
- **Persistencia NoSQL:** Escalabilidad y rendimiento para flujos de IA.

Gobernanza y Aislamiento

- **Suscripción del Cliente:** Los recursos se aprovisionan en el entorno del cliente.
- **Aislamiento Robusto:** Control total sobre la residencia y retención de datos.
- **Auditabilidad:** Cumplimiento de normativas empresariales de seguridad.

Importante: Para evitar inconsistencias, otras aplicaciones no deben interactuar directamente con las colecciones gestionadas por el servicio.

Almacenamiento Dedicado con Azure Storage

New Horizons®
Centro de Capacitación

El runtime de **Foundry Agent Service** utiliza cuentas de almacenamiento dedicadas en la **suscripción del cliente** para gestionar de forma segura los archivos de las sesiones de chat.

Control de Acceso Granular

Gestión precisa de quién puede leer o escribir archivos utilizando políticas de identidad nativas de Azure.

Capacidades de Auditoría

Registro completo de accesos y modificaciones para cumplir con los requisitos de seguridad corporativa.

Residencia de Datos

Asegura que los documentos y archivos permanezcan dentro de las fronteras geográficas definidas por la organización.

Gobernanza y Retención

Aplicación de políticas de ciclo de vida de datos y retención legal directamente sobre el almacenamiento dedicado.

** Nota: El servicio gestiona los datos, pero la propiedad y el control de la infraestructura pertenecen íntegramente al cliente.*

Aislamiento y Seguridad de los Datos

New Horizons®
Centro de Capacitación

La arquitectura de Foundry garantiza que el control de los datos permanezca siempre en manos del cliente a través de un modelo de **recursos delegados**.

Suscripción del Cliente

Todos los recursos de persistencia (Azure Cosmos DB y Azure Storage) se aprovisionan dentro de la propia suscripción de Azure del cliente.

Aislamiento y Auditoría

Garantiza un aislamiento robusto y permite el cumplimiento de políticas de residencia, retención y auditoría de datos empresariales.

Gobernanza Total

El cliente mantiene el control granular del acceso y la gestión de claves sobre la infraestructura que soporta al agente.

Gestión Exclusiva

Foundry gestiona los datos de forma exclusiva; se recomienda no interactuar externamente con estos recursos para evitar inconsistencias.

"La seguridad por diseño asegura que Foundry Agent Service actúe como orquestador sin comprometer la soberanía de los datos."

Patrón Asíncrono de Larga Duración

New Horizons®
Centro de Capacitación

Optimización de flujos que exceden los tiempos de espera HTTP estándar (30s a varios minutos), garantizando resiliencia y continuidad.

PASO 1

Solicitud Inicial

La API devuelve inmediatamente un estado **202 Accepted** junto con un ID de tarea único.

PASO 2

Procesamiento en Background

Un trabajador en segundo plano ejecuta el flujo de trabajo complejo del agente sin bloquear al cliente.

PASO 3

Persistencia de Estado

El progreso y los resultados se guardan de forma duradera en **Azure Cosmos DB**.

PASO 4

Monitoreo y Resultado

El cliente consulta periódicamente el estado mediante el ID de tarea para obtener el resultado final.

Evita Timeouts y mejora la experiencia del usuario con feedback en tiempo real.

Integración con Model Context Protocol (MCP)

New Horizons
Centro de Capacitación

El "USB-C" para las aplicaciones de IA

Un estándar abierto diseñado para **estandarizar las integraciones** entre modelos de IA, herramientas y fuentes de datos externas.

Conexión Universal

Elimina la necesidad de integraciones personalizadas para cada herramienta o periférico.

Capacidades Extendidas

Permite a los modelos invocar funciones externas y acceder a APIs de terceros de forma nativa.

Conciencia Contextual

Suministra datos de negocio en tiempo real para generar respuestas precisas y relevantes.

Facilitando la interoperabilidad en el ecosistema .NET

ESTÁNDAR ABIERTO

Optimización de Respuestas: Grounding con Foundry IQ

New Horizons
Centro de Capacitación

Sistema de Conocimiento Centralizado

Foundry IQ actúa como el núcleo de información, eliminando la necesidad de gestionar múltiples fuentes de datos de forma individual. Permite una conexión unificada a toda la base de conocimiento corporativa.

Recuperación Agéntica

Búsqueda inteligente que entiende el contexto del agente para extraer solo la información más relevante.

Fuentes Conectadas

- SharePoint
- Fabric OneLake
- Web Corporativa

Impacto en Calidad

Respuestas fundamentadas (grounded) con contexto profundo, reduciendo alucinaciones y aumentando la precisión.

Impulsado por Azure AI Search para una escalabilidad y seguridad de nivel empresarial.

Orquestación Multi-Agente

New Horizons®
Centro de Capacitación

Sustitución de sistemas monolíticos por ecosistemas de agentes especializados.

Análisis de Datos

Procesamiento profundo y extracción de insights técnicos.

Redacción

Generación de informes y documentación estructurada.

Interacción

Gestión de la comunicación directa con el usuario final.

Mayor Calidad | **Alta Precisión** | **Eficiencia Operativa**

Selección Inteligente con Model Router

New Horizons
Centro de Capacitación

El **Model Router** actúa como una capa de orquestación de IA que selecciona automáticamente el LLM más adecuado para cada prompt en tiempo real.

Complejidad

Evalúa la dificultad del prompt para asignar el nivel de razonamiento necesario.

Rendimiento

Considera los requisitos de velocidad y latencia para la respuesta.

Costo

Optimiza el gasto seleccionando el modelo más eficiente para la tarea.

Modelos Pequeños y Económicos

Ideales para tareas simples, extracciones de datos básicas o prompts con baja ambigüedad.

↔

Modelos de Alta Potencia

Reservados para consultas complejas, razonamiento avanzado o síntesis de información densa.

Optimización automática sin intervención manual del desarrollador

Gestión Eficiente de Schedules

New Horizons
Centro de Capacitación

Eventos vs. Tiempo

Priorice disparadores basados en **cambios de datos** en lugar de intervalos fijos para reducir ejecuciones innecesarias.

Ajuste de Frecuencia

Alinee el schedule con el uso real. Desactivar ejecuciones en fines de semana puede ahorrar hasta un **30% de cómputo**.

Eliminar Duplicados

Utilice **Data Lineage** para identificar y consolidar schedules redundantes, evitando colas y ralentizaciones.

Pipelines Incrementales

Prefiera transacciones **APPEND** sobre SNAPSHOT para sincronizar solo datos nuevos y ahorrar recursos.

Configuración Avanzada

- Abortar en fallo
- Límite de reintentos (ej. 3)
- Tiempo de espera estratégico

New Horizons
Centro de Capacitación

Conclusiones

Robustez y Escalabilidad

Integración nativa de .NET con Foundry para soluciones de nivel empresarial.

Seguridad y Gobernanza

Aislamiento total de datos en la suscripción del cliente con Azure Cosmos DB.

Inteligencia Contextual

Gestión avanzada de memoria y grounding con Foundry IQ para respuestas precisas.

GRACIAS